

タイプミス傾向の分析に基づく タイポスクワッティングドメイン生成モデルの提案

菅原 颯真^{1,a)} 星名 藍乃介¹ 上原 哲太郎^{2,b)}

概要：タイポスクワッティングは、正しいドメインの一部を改変した類似のドメインを生成し、ユーザを意図しない Web サイトやメールの宛先に誘導する攻撃手法である。メールにおけるタイポスクワッティングへの対策として、タイポスクワッティングドメインの防御的登録が有効であるとされている。しかし、多数のタイポスクワッティングドメインの防御的登録には多額の費用がかかるため、ユーザがタイプミスしやすいドメインから優先的に防御的登録を行うことが必要である。本研究では、関連研究で取り扱われていないタイポスクワッティングドメインについても調査し、メールにおけるタイポスクワッティングドメイン生成モデルの提案を目的とする。これにより、タイポスクワッティングドメインに対するメール誤送信の防止に寄与することを目指す。調査には Yahoo!クラウドソーシングを活用し、メールアドレスの入力者がタイプミスしたドメインを収集し、収集したデータをもとに、タイポスクワッティングドメインの生成モデルを提案する。

キーワード：メール誤送信, タイポスクワッティング, タイプミス

Proposal of a Typosquatting Domain Generation Model based on the analysis of Typographical Error Tendencies

SUGAHARA SOMA^{1,a)} HOSHINA RANNOSUKE¹ UEHARA TETSUTARO^{2,b)}

Abstract: Typosquatting is an attack technique that generates domain names similar to legitimate ones by altering parts of the domains. The goal of this technique is to mislead users into accessing unintended websites or misdirecting emails. As a countermeasure against typo-squatting in email systems, defensive registration of typosquatting domains is effective. However, registering a large number of typosquatting domains for defensive purposes may lead to significant costs. Therefore, it is desirable to prioritize the registration of domains that email users are more likely to mistype. To contribute to the prevention of email misdirecting behavior, this study proposes a typosquatting domain generation model for emails. In addition, the study investigates a group of typosquatting domains that have not been covered in existing research. This study has collected a database of the frequently mistyped email domains by users from the survey results obtained from Yahoo! crowdsourcing, this database will then be used for the enhancement of the proposed model.

Keywords: Misdirected E-mails, Typosquatting, Typos

¹ 立命館大学 大学院情報理工学研究科
Graduate School of Information Science and Engineering,
Ritsumeikan University

² 立命館大学 情報理工学部
College of Information Science and Engineering, Rit-
sumeikan University

a) sugahara@cysec.cs.ritsumeai.ac.jp

b) t-uehara@fc.ritsumeai.ac.jp

1. はじめに

ユーザのタイプミスを利用し、意図しない Web サイトやメールの宛先へ誘導する手法として、タイポスクワッティングがある。本研究におけるタイプミスは、キーボードの打ち間違いのみならず、ユーザの見間違いや入力忘れ

等により、誤った文字列を入力することを指す。タイポスクワッティングは、正しいドメイン（以下、オリジンドメイン）の一部を改変した類似のドメインを生成し、ユーザを意図しない Web サイトやメールの宛先に誘導する攻撃手法である。タイポスクワッティングは、フィッシング詐欺等で利用されるのみならず、メールの宛先を誘導する手法としても利用される。Web サイトにおけるタイポスクワッティングは、ブラウザ側でタイプミスしたドメインを補正する等の対策が取られているが、メールにおけるタイポスクワッティングは、送信側での対策が取られていない場合が多い。そこで、本研究ではメールにおけるタイポスクワッティングに着目する。

ユーザがタイプミスした際に誘導されるドメインで、オリジンドメインの一部を変更した類似のドメインを、タイポスクワッティングドメインと呼ぶ。例えば、「gmail.com」のタイポスクワッティングドメインとして、「gmai.com」や「gmeil.com」などが挙げられる。

日本において、タイポスクワッティングドメインに対するメール誤送信事例は毎年報告されている [1-3]。海外においても、タイポスクワッティングドメインに対するメール誤送信は発生しており、個人情報・機密情報の漏洩が発生している事例も報告されている [4,5]。また、タイポスクワッティングは、著名でないドメインに対しても行われている [6]。このことから、企業の規模に関わらず、タイポスクワッティングへの対策が必要である。

タイポスクワッティングへの対策として、タイポスクワッティングドメインの防御的登録がある。タイポスクワッティングドメインの防御的登録とは、オリジンドメインの所有者がそのドメインのタイポスクワッティングドメインを取得することである。これにより、悪意のある第三者によるタイポスクワッティングを防ぐことで、企業のブランドを保護できる。メールにおけるタイポスクワッティングの対策としてタイポスクワッティングドメインの防御的登録がもっとも有効であるとされている [4]。しかし、オリジンドメインと編集距離が 1 のタイポスクワッティングドメインをすべて防御的登録するだけでも多額の費用がかかるため、ユーザがタイプミスしやすいドメインから優先的に防御的登録を行う必要がある [7]。

本研究では、Yahoo!クラウドソーシングを用いて、メールアドレスの入力者がタイプミスしたドメインを収集・分析し、収集したデータをもとにタイポスクワッティングドメインの生成モデルを提案し、その有効性を評価する。

2. 関連研究

2.1 タイポスクワッティングの現状

Szurdi ら [4] は、74 個のタイポスクワッティングドメインを取得し、7 か月間にわたりそのドメインに送信されたメールの受信状況を調査した。Szurdi らは、オリジンドメ

インと編集距離が近いドメインだけでなく、キーボード上のキーが近接している、ファットフィンガー距離が近いドメインや、文字の見た目が類似している、視覚距離が近いドメインもタイポスクワッティングドメインとして選定した。Szurdi らは、7 か月間で約 6,000 通の誤送信されたメールを受信し、それらのメールの中には、パスワードや医療情報等の機密情報が含まれているものがあったと報告している。また、Szurdi ら [6] は、Web サイトにおいてアクセス頻度が低いドメインに対してもタイポスクワッティングが行われているかを調査した。Szurdi らにより、Alexa ランキングの上位 100 万のドメインを対象に調査した結果、下位のドメインにおいてもタイポスクワッティングドメインが存在することが明らかになった。このことから、どのドメインにおいてもタイポスクワッティングによって機密情報を含むメールが漏洩する可能性があるため、対策が必要である。

2.2 メールにおけるタイポスクワッティングの対策

Szurdi ら [4] は、メールにおけるタイポスクワッティングの対策として防御的登録がもっとも有効であり、費用対効果が高いと報告している。ただし、Szurdi らは小規模の企業がタイポスクワッティングドメインをいくつも登録することは金銭的に負担がかかると述べている。また、Pouryousef ら [7] は、タイポスクワッティングドメインの防御的登録にかかる費用を調査した。Pouryousef らは、1 つのタイポスクワッティングドメインの防御的登録にかかる初期費用は、平均 95 米ドルであり、オリジンドメインと編集距離が 1 のタイポスクワッティングドメインをすべて防御的登録する場合には、数百万米ドルの費用がかかると報告している。よって、多数のタイポスクワッティングドメインを防御的登録することは合理的でないといえる。

2.3 タイポスクワッティングドメインの生成

Ahmad ら [8] は、bd ドメインへのアクセスに関する DNS ログを 6 か月間収集し、タイポスクワッティングドメインの生成に関する研究を行った。Ahmad らは、サードレベルドメインにおいて、オリジンドメインと編集距離が 1 のタイポスクワッティングドメインを約 3500 件収集し、機械学習を用いてタイポスクワッティングドメインの生成モデルを提案した。

3. 研究目的

1 章より、タイプミスによるメール誤送信は毎年報告されており、個人情報の漏洩が発生している。このような問題を解決する手法の 1 つとして、タイポスクワッティングドメインの防御的登録がある。しかし、2.2 節で述べたとおり、多数のタイポスクワッティングドメインを防御的登録するには、多額の費用がかかる。そのため、ユーザがタ

Szurdiら: {2LD}.com

Ahmadら: {3LD}.{2LD}.bd

本研究: {3LD}.{2LD}.{TLD}

図 1: 各研究における研究対象のドメイン

イプミスしやすいドメインから優先的に防御的登録することが必要である。

そこで、本研究では関連研究で取り扱われていないタイポスクワッシングドメインを調査し、メールにおけるタイポスクワッシングドメインの生成モデルを提案することを目的とする。これにより、様々なオリジンドメインに対して効果的なタイポスクワッシングドメインの生成が可能となる。本論文では、本研究の初期段階として、日本を対象にタイポスクワッシングの調査および生成モデルの提案を行う。

4. 研究対象のドメイン

本研究では、タイポスクワッシングドメインとなりうるドメインを収集するために、以下のドメインを研究対象とする。

- (1) RFC5321 [9] および RFC5322 [10] に準拠している。
- (2) 3LD, 2LD, TLD のいずれかにタイプミスがある。
- (3) オリジンドメインと Damerau-Levenshtein 距離が 1～5 である。

(1) について述べる。本研究では、実際に取得可能なドメインを研究対象とする。つまり、RFC5321 [9] および RFC5322 [10] に準拠したドメインであり、かつトップレベルドメイン（以下、TLD）が IANA によって管理されている有効な TLD [11] であるドメインを研究対象とする。

(2) について述べる。オリジンドメインのうち、どの部分のタイプミスを研究対象とするかを明確にする。図 1 に示すように、関連研究において、Szurdi ら [6] は、TLD が「com」であるドメインのセカンドレベルドメイン（以下、2LD）を研究対象としている。また、Ahmad ら [8] は、TLD が「bd」であるドメインのサードレベルドメイン（以下、3LD）を研究対象としている。一方、本研究では上記に加えて、関連研究で研究対象としていない、以下の部分も研究対象とする。

- TLD
- 3LD と 2LD の間のドット（.）

例えば、TLD のタイプミスとしては、「.com」を「.co」と入力するなどが挙げられる。また、3LD と 2LD の間のドット（.）のタイプミスとしては、「example.co.jp」を「exampleco.jp」と入力するなどが挙げられる。

(3) について述べる。関連研究として、Szurdi ら [6] は、オリジンドメインと Damerau-Levenshtein 距離 [12]（以

表 1: 各研究における研究対象となるタイプミスの収集範囲と種類

	タイプミスの収集範囲			タイプミスの種類			
	TLD	2LD	3LD	削除	挿入	置換	転置
Szurdi ら	com	✓	-	✓	✓	✓	✓
Ahmad ら	bd	-	✓	✓	✓	✓	-
本研究	✓	✓	✓	✓	✓	✓	✓

✓ 各研究において研究対象であることを指す。

- 各研究において研究対象でないことを指す。

下、DL 距離）が 1 のドメインを研究対象としている。DL 距離は、一方の文字列をもう一方の文字列へ変換するために必要な最小操作回数を表す距離である。なお、「操作」とは 1 文字の挿入、削除、置換、あるいは 2 つの隣り合う文字の交換のいずれかを 1 回行うことを指す。一方、本研究では DL 距離が 2～5 のドメインも研究対象とする。

最後に、表 1 に、関連研究と本研究で研究対象とするタイプミスの範囲と種類を示す。本研究では、関連研究では取り扱われていない TLD においてタイプミスがあるドメインや、DL 距離が 2 以上のドメインも研究対象としている。以降、本研究では研究対象のドメインを**タイポドメイン**と呼ぶ。

5. 調査

タイポドメインを収集する手順について、以下に示す。

- (1) 調査参加者に入力させるメールアドレスを用意する。
- (2) 調査用 Web サイトを作成する。
- (3) クラウドソーシングサービスを利用して調査参加者を募集し、メールアドレスの入力データを収集する。
- (4) 収集したデータから、タイポドメインを抽出する。

5.1 調査に使用するメールアドレスの作成

本調査では、日本において使用されうるメールアドレスを用いる。そのため、ドメインについては、日本 DNS オペレーターズグループが提供する TOPIX 銘柄企業のドメイン一覧 [13] に掲載されているドメインのうち、MX レコードが設定されている 2,138 個のドメインを使用する。入力されるドメインの偏りを防ぐため、全ドメインを均等に使用する。また、ローカルパートについては、日本人の名前を用いることとする。

5.2 調査用 Web サイトの作成

調査参加者にメールアドレスを入力してもらうための調査用 Web サイトを作成する。一般社団法人日本ビジネスメール協会の調査 [14] によると、仕事でもっとも利用されているメールソフトは、Microsoft Outlook である。本調査では、実際のメール送信状況に近い環境を再現するため、Microsoft Outlook の UI を模倣した調査用 Web サイトを設計する。調査用 Web サイトの UI を、図 2 に示す。




図 2: 調査用 Web サイトの UI

また、調査用 Web サイトにおいて、調査参加者が行う操作は、以下の操作手順を 1 ステップとして、練習を 3 ステップ、本番を 8 ステップの計 11 ステップとする。

- (1) 画面左下に表示されるメールアドレス、会社名、宛先フィールドを確認する。
- (2) 画面右上のメールアドレス入力欄に、(1) で確認した各メールアドレスを入力する。
- (3) すべてのメールアドレス入力後、画面右上の「送信」ボタンをクリックし、次のステップに進む。

タイプミスを誘発させるために、本番では、練習におけるメールアドレスの平均入力時間の 0.9 倍を制限時間とする。調査参加者一人につき、8 ステップで合計 40 個のメールアドレスを入力させる。

5.3 クラウドソーシングサービスによる調査参加者の募集

調査参加者は合計で 300 人とし、性別による偏りを防ぐために、男女それぞれ 150 人に分けて募集する。調査参加者を集めるにあたって、Yahoo!クラウドソーシング [15] を利用した。Yahoo!クラウドソーシングは、日本人のユーザが多いことから、日本におけるタイプミスを収集することに適していると考えた。Yahoo!クラウドソーシングでの調査参加者の募集において、以下の募集条件を記載した。

- ・ 年齢が 18 歳以上 60 歳未満で、日本語に堪能
- ・ PC で Outlook を使用したメール送信経験あり
- ・ PC かつ、JIS・US 配列のキーボードで参加可能

5.4 タイポドメインの抽出

タイポドメインを抽出する流れを図 3 に示す。

収集テーブルは、調査参加者が入力すべきメールアドレス（以下、オリジンメールアドレス）と調査参加者に入力されたメールアドレスを保存しているテーブルである。まず、4 章より、収集テーブルから、RFC5322 および RFC5321 に準拠していないメールアドレス、もしくは TLD が存在しないドメインをもつメールアドレスを除外する。次に、収集テーブルのオリジンメールアドレス、入力されたメールアドレスのドメインをそれぞれ比較し、DL 距離が 1～5

収集テーブル		タイポドメインテーブル		
オリジンメールアドレス	入力されたメールアドレス	オリジンドメイン	タイポドメイン	DL 距離
taro.yamada@example.com	taro.yamada@exampl.com	example.com	exampl.com	1
thanako@example.jp	thanako@example.jp	example.co.jp	examplee.co.jp	1
sato@example.co.jp	sato@examplelee.co.jp	example.ne.jp	example.jp	3
goro_tanaka@example.ne.jp	golo_tanaka@example.ne.jp	:	:	:

図 3: タイポドメインの抽出

タイポドメインテーブル			差分テーブル (DL1ドメイン)		
オリジンドメイン	タイポドメイン	DL 距離	オリジン文字列	タイポ文字列	操作
example.com	exampl.com	1	le.	L.	削除
example.co.jp	examplee.co.jp	1	e.	ee.	挿入
example.ne.jp	example.jp	3	:	:	:
:	:	:	:	:	:

(i)

差分テーブル (DL2+ドメイン)		
オリジン文字列	タイポ文字列	操作
.ne.jp	.jp	削除
:	:	:

(ii)

(a) 差分テーブルの作成

差分テーブル			差分テーブル				
オリジン文字列	タイポ文字列	操作	オリジン文字列	タイポ文字列	操作	個数	発生確率
le.	L.	削除	le.	L.	削除	3	20.11%
e.	ee.	挿入	e.	ee.	挿入	1	3.45%
.ne.jp	.jp	削除	.ne.jp	.jp	削除	2	5.64%
:	:	:	:	:	:	:	:

(b) タイポケースの発生数・発生確率の抽出

図 4: タイポドメインの分析の流れ

であれば、入力されたメールアドレスのドメインをタイポドメインとして、タイポドメインテーブルに追加する。

6. 分析

5 章で述べた調査より、合計で 916 個のタイポドメインが抽出された。916 個のタイポドメインから、オリジンドメインと DL 距離が 1 であるタイポドメイン（以下、DL1ドメイン）が 745 個、オリジンドメインと DL 距離が 2 以上であるタイポドメイン（以下、DL2+ドメイン）が 171 個抽出された。DL1 ドメインと DL2+ドメインのそれぞれについて、詳細に分析する。

6.1 分析手法

分析の流れを図 4 に示す。

図 4a では、タイポドメインテーブルから、オリジンドメインとタイポドメインの差分を抽出し、差分が出た部分をそれぞれオリジン文字列、差分文字列として、差分テーブルに追加する。また、本研究ではオリジン文字列と差分文字列の組み合わせをタイポケースと呼ぶ。

表 2: DL1 ドメインにおける操作別のタイポケース発生数の分布

操作	1 回	2 回	3 回	4 回	5 回以上	合計
削除	139	12	2	3	2	158
挿入	128	7	3	2	0	140
置換	260	15	5	3	6	289
転置	17	2	0	1	0	20
合計	544	36	10	9	8	607

(i) では、DL1 ドメインから、タイポケースを抽出する。タイポケースの抽出においては、そのタイポケースが発生する原因となった操作ごとに以下の差分に着目する。

削除 削除された文字と、その前後の文字

挿入 挿入された文字と、その前後の文字

置換 置換された文字、置換した文字と、その前後の文字

転置 転置された 2 文字

動的計画法による DL 距離算出アルゴリズムをバックトラックすることで、タイポケースを抽出する

(ii) では、DL2+ドメインからタイポケースを抽出する。DL2+ドメインについては、各操作が 2 回以上行われており、単に、離れた文字に対して 1 回ずつ操作されているのではなく、数文字単位で操作が見られた文字列をタイポケースとして抽出する。DL2+ドメインについては、目視でタイポケースを抽出する。

図 4b では、タイポケースごとの発生数および発生確率を分析する。タイポケースの発生数とは、差分テーブル内におけるタイポケースの出現数を指す。タイポケースの発生確率とは、調査においてオリジン文字列が入力された回数のうち、タイポケースに該当するタイプミスが発生した割合を指す。「.com」のような、メールアドレスの入力においてよく入力される文字列がタイポケースのオリジン文字列である場合、タイポケースの発生数が高くなると予想される。そのため、発生数だけでは入力されやすいタイポケースを正確に評価することが難しい。発生確率を分析することで、タイポケースがどの程度発生しているかをより正確に把握できる。

6.2 DL1 ドメインの分析結果・考察

まず、DL1 ドメインについて分析する。DL1 ドメインについて、6.1 節で述べたタイポケースの抽出を行った結果、607 個のタイポケースが抽出された。

DL1 ドメインにおける、操作別のタイポケース発生数の分布を表 2 に示す。表 2 から、発生数が 1 回のタイポケースが各操作においてもっとも多く収集できたことがわかる。これは、本研究において約 2000 ドメインを各ドメイン 6 回ほどしか調査参加者に入力してもらっておらず、同じような文字列を複数回入力することが少なかったためと考えられる。

次に、複数回出現し、かつ発生確率が 1%以上のタイポケースに絞って、各操作におけるタイポケースを分析した結果を表 3 に示す。なお、転置については、データ数が小さいため分析対象外とする。

6.2.1 削除

削除によるタイポケースの分析結果を表 3a に示す。No.1~4 は、日本語で読んだ際に発音されない文字が削除されたと考えられる。例えば、No.1 の「oh」の「h」は日本語で発音したとき、伸ばし棒にあたるため発音されない。No.5 は、複数形の「s」を入力し忘れたと考えられる。No.6, 7 は、ヘボン式ローマ字を訓令式ローマ字で入力したと考えられる。また、発生確率が 1%未満であることから、表 3a には掲載していないが、関連研究において見られなかった、3LD と 2LD の間のドット (.) が削除されるタイプミスも見られた。

6.2.2 挿入

挿入によるタイポケースの分析結果を表 3b に示す。No.1, 3 は、訓令式ローマ字をヘボン式ローマ字で入力したと考えられる。No.2 は、「toyo」を「tokyo」に見間違えたと考えられる。

6.2.3 置換

置換によるタイポケースの分析結果を表 3c に示す。No.1, 8 は、日本語の発音において「s」と「c」の区別がないこと [16] が影響したと考えられる。No.2, 4, 9, 12 は、ヘボン式ローマ字を訓令式ローマ字で入力したと考えられる。No.3, 5 は、視覚距離が近いことが影響したと考えられる。No.6, 7 は、母音を日本語の発音に基づいて入力したと考えられる。No.10, 11, 13 は、ファットフィンガー距離が近いことが影響したと考えられる。

6.3 DL2+ドメインの分析結果・考察

次に、DL2+ドメインについて分析する。DL2+ドメインについて、6.1 節で述べたタイポケースの抽出を行った結果、21 個のタイポケースが抽出された。DL2+ドメインについては、6.2 節で述べたタイポケースが 1 つのドメインで 2 回以上発生したタイポケースがほとんどであった。一方で、ある数文字を一括りとして、削除、挿入、置換の操作が行われたタイポケースについて表 4 に示す。No.1, 2, 6 は、見落としによる入力忘れだと考えられる。No.3 は、日本語の発音に基づいて入力したと考えられる。No.4, 5, 7, 9 は、TLD および 2LD を誤認識したと考えられる。No.8 は、ヘボン式ローマ字を訓令式ローマ字で入力したと考えられる。

6.4 まとめ

分析結果より、タイポケースは大きく以下のようにまとめられる。

(1) ヘボン式ローマ字と訓令式ローマ字の混同

表 3: タイポケースの分析結果 (DL1 ドメイン)

(a) 削除によるタイポケースの分析結果

No.	オリジン文字列	タイポ文字列	発生数	発生確率	例
1	ohs	os	2	11.76%	ohsho.co.jp → osho.co.jp
2	acc	ac	2	9.52%	raccoon.ne.jp → racoon.ne.jp
3	ard	ad	2	6.25%	moneyforward.com → moneyforwad.com
4	arm	am	4	5.13%	pharmarise.com → phamarise.com
5	ds.	d.	4	3.74%	ebarafoods.com → ebarafood.com
6	tsu	tu	10	2.17%	tsumura.co.jp → tumura.co.jp
7	shi	si	8	1.33%	nisshin.com → nissin.com

(b) 挿入によるタイポケースの分析結果

No.	オリジン文字列	タイポ文字列	発生数	発生確率	例
1	tu	tsu	2	3.57%	osaka-seitetu.co.jp → osaka-seitetsu.co.jp
2	oy	oky	4	2.74%	toyo-sec.co.jp → tokyo-sec.co.jp
3	si	shi	2	1.05%	sinko.co.jp → shinko.co.jp

(c) 置換によるタイポケースの分析結果

No.	オリジン文字列	タイポ文字列	発生数	発生確率	例
1	rce	rse	2	9.09%	cellsource.co.jp → cellsourse.co.jp
2	shu	syu	4	8.70%	kyushu-fg.co.jp → kyusyu-fg.co.jp
3	elc	eic	2	8.33%	belc.jp → beic.jp
4	sha	sya	5	7.58%	doshisha.co.jp → doshisya.co.jp
5	all	ail	2	7.41%	aeonmall.com → aeonmail.com
6	mon	man	3	7.32%	moneyforward.com → maneyforward.com
7	sun	san	2	4.76%	sunwa.co.jp → sanwa.co.jp
8	^ch	^sh	5	3.88%	chofu.co.jp → shofu.co.jp
9	sho	syo	6	3.70%	takasho.co.jp → takasyo.co.jp
10	art	aet	2	2.63%	win-partners.co.jp → win-paetners.co.jp
11	oba	ona	2	1.61%	tokyobase.co.jp → okyonase.co.jp
12	^fu	^hu	3	1.17%	furukawa.co.jp → hurukawa.co.jp
13	ex.	es.	2	1.06%	torex.co.jp → tores.co.jp

^ 文頭を表す。

表 4: タイポケースの分析結果 (DL2+ドメイン)

No.	オリジン文字列	タイポ文字列	操作	発生数	発生確率	例
1	tokyoto	tokyo	削除	2	40.00%	tokyotokeiba.co.jp → tokyokeiba.co.jp
2	-sugi		削除	2	25.00%	drug-sugi.co.jp → drug.co.jp
3	group	grope	置換	3	1.29%	meiji-group.com → meiji-grope.com
4	.jp	.co.jp	置換	10	1.12%	taikobank.jp → taikobank.co.jp
5	.com	.co.jp	置換	9	0.52%	tte-net.com → tte-net.co.jp
6	-hd		削除	2	0.51%	tokyu-fudosan-hd.co.jp → tokyu-fudosan.co.jp
7	.co.jp	.jp	置換	17	0.19%	teldevice.co.jp → teldevice.jp
8	chi	ti	置換	2	0.15%	daiichipan.co.jp → daiitipan.co.jp
9	.co.jp	.com	置換	3	0.03%	eguarantee.co.jp → eguarantee.com

- (2) 日本語の発音に基づく入力
- (3) TLD および 2LD のタイプミス・置換
- (4) 3LD と 2LD の間のドット (.) の削除
- (5) 見間違い・見落とし
- (6) 視覚距離の近さ
- (7) ファットフィンガー距離の近さ

(1) ~ (5) は関連研究においては見られなかったタイプ

ミスであり、本研究の貢献点といえる。また、DL2+ドメインにおいて、一定の傾向が見られたことも本研究の貢献点である。(1), (2) は、日本人特有のタイプミスであり、国ごとに異なった傾向があることが推察される。このような、言語や地域の特徴を狙ったタイポスクワッシングドメインは、その言語を使用するユーザがタイプミスによりメール誤送信をしてしまう可能性が高いことから、優先的




図 5: 提案する生成モデルの概要

に防御的登録を行うことが必要である。特に、ある特定の国や地域を対象にサービスを提供している企業は、その国や地域の言語や文化に基づくタイプミスに対して、防御的登録を行うことが重要であるといえる。(3)、(4)は、日本に限ったタイプミスではなく、他の国や地域でも見られる可能性があるタイプミスである。「.com」と「.co.jp」等のTLDおよび2LDの置換や、「*.co.jp」と「*co.jp」等の3LDと2LDの間のドット(.)の削除を狙ったタイポスクワッティングドメインは、どのオリジンドメインでも狙われる可能性があるため、優先的に防御的登録を行うことが必要であるといえる。

7. 生成モデルの提案

本研究で提案する生成モデルは、収集したデータが小さいことからルールベースの生成モデルを採用する。生成モデルは大きく、タイポケースの作成とタイポスクワッティングドメインの生成の2つのステップから構成される。生成モデルの概要を図5に示す。

7.1 タイポケースの作成

タイポケースの作成は、5章および6章で述べた手順と同様に行う。タイポケースを保存する差分テーブルの作成を行ったのち、発生確率で降順にソートする。また、分析結果より、2回以上発生したタイポケースに一定の傾向が見られたことから、発生数が2以上のタイポケースを発生確率に関わらず、発生数が1のすべてのタイポケースよりも上位に配置する。

7.2 タイポスクワッティングドメインの生成

7.1節で作成したタイポケースをもとに、タイポスクワッティングドメインを生成する。生成モデルに入力されたオリジンドメインに対して、以下の手順に従ってタイポスクワッティングドメインを生成する。なお、タイポスクワッティングドメインの生成は、差分テーブルの参照が終了するまで繰り返す。

- (1) 差分テーブルを上から参照する。
- (2) オリジンドメインに差分テーブルのオリジン文字列が含まれているかを確認する。




図 6: 評価手法の概要

- (3) オリジン文字列が含まれている場合、オリジンドメインのオリジン文字列を差分文字列に置換する。
- (4) 置換したドメインをタイポスクワッティングドメインとして、タイポケースの発生確率とともに出力する。

8. 評価

8.1 評価指標

提案した生成モデルを以下の2点で評価する。

- (1) タイポスクワッティングドメインの生成数
- (2) 生成モデルの網羅率

8.2 評価手法

評価手法の概要を図6に示す。本研究では収集したデータが916個と比較的小さいことから、5分割交差検証を行う。そのため、タイポドメインテーブルを5つに分割し、そのうちの1つをテストデータ、残りの4つを登録用データとして使用する。登録用データのタイポドメインテーブルをもとに生成された差分テーブルをルールとして、テスト用のオリジンドメインに対してタイポスクワッティングドメインの一覧を生成する。(1)を評価するために、テストデータの各オリジンドメインから生成されたタイポスクワッティングドメイン一覧の数をカウントする。(2)を評価するために、テストデータのタイポドメインが、生成されたタイポスクワッティングドメイン一覧に含まれるのかを調査した。また、テストデータのタイポドメインが上位*k*件に含まれるかも合わせて調査した。

8.3 評価結果

まず、タイポスクワッティングドメインの生成数を評価する。各テストデータにおける平均生成数は、それぞれ 21.08 ± 7.42 件、 23.60 ± 7.26 件、 21.86 ± 6.75 件、 22.50 ± 7.03 件、 23.94 ± 7.59 件であり、5つのテストデータの平均生成数は22.60件であった。

次に、生成モデルの網羅率を評価する。5つのテストデータにおいて、タイポスクワッティングドメイン一覧のうち、上位*k*件にタイポドメインが含まれている確率の平均値を図7に示す。




図 7: 生成モデルの網羅率

8.4 考察

まず、タイポスクワッシングドメインの生成数について考察する。生成数は、テストデータによってばらつきがあるが、平均 22.60 件となり、どのオリジンドメインに対しても一定量のタイポスクワッシングドメインを生成できることがわかった。これは、約 2000 件のドメインを使ってタイポケースを収集したことによる効果であると考えられる。

次に、生成モデルの網羅率について考察する。生成モデルの網羅率は、登録用データが約 700 件と少なく、かつ 1 回のみ発生したタイポケースが約 90%を占めるにもかかわらず、テストデータの約 25%を網羅できた。関連研究 [8] では、テストデータの約 43%を網羅しており、本研究よりも高い精度を達成している。しかし、関連研究は学習に使用したデータが 500GB と大規模かつ、3LD のタイプミスのみを研究対象としていることから、高い精度を達成していると考えられる。また、 $k = 30$ 付近で網羅率が 25%に収束することが明らかとなった。このことから、 $k = 30$ を超えてタイポスクワッシングドメインの防御的登録を行ったとしても、その効果は限定的であるといえる。

9. おわりに

本研究では、調査用 Web サイトを用いて、タイポスクワッシングドメインを収集・調査し、収集したタイポケースに基づいてタイポスクワッシングドメイン生成モデルを提案した。調査結果より、関連研究では取り扱われなかったタイポケースを明らかにした。また、関連研究では取り扱われなかったタイポスクワッシングドメインの生成が可能となり、幅広いタイポスクワッシングドメインの防御的登録に貢献する。さらに、タイポスクワッシングドメインの防御的登録における効果の限界基準を示し、効果的な防御的登録のための指針を示した。

今後は、日本だけでなく、世界中のユーザに対してタイポスクワッシングドメインの生成モデルを提案するため、海外での大規模なタイポドメインの収集や、生成モデルの精度向上を目指す。

参考文献

- [1] 大阪教育大学：電子メール転送先ミスによる情報漏えいについて、大阪教育大学（オンライン），入手先 (<https://osaka-kyoiku.ac.jp/news/detail.html?itemid=8224&dispmid=5662>)（参照 2024-12-29）。
- [2] 会津大学：メールの誤送信について、会津大学（オンライン），入手先 (<https://u-aizu.ac.jp/information/post-20230121.html>)（参照 2024-12-29）。
- [3] 福岡県庁：県職員等の人間ドック受診者情報のデータの誤送信について、福岡県庁（オンライン），入手先 (<https://www.pref.fukuoka.lg.jp/press-release/kensyokuin-jushinsyajoho.html>)（参照 2024-12-29）。
- [4] Szurdi, J. and Christin, N.: Email typosquatting, *Proceedings of the 2017 Internet Measurement Conference, IMC '17*, New York, NY, USA, Association for Computing Machinery, p. 419–431 (online), DOI: 10.1145/3131365.3131399 (2017).
- [5] Jacob, J., Chris, C., Mehul, S. and Max, H.: Typo leaks millions of US military emails to Mali web operator, *Financial Times* (online), available from (<https://www.ft.com/content/ab62af67-ed2a-42d0-87eb-c762ac163cf0>) (accessed 2025-1-12).
- [6] Szurdi, J., Kocso, B., Cseh, G., Spring, J., Felegyhazi, M. and Kanich, C.: The long {“Taile”} of typosquatting domain names, *23rd USENIX Security Symposium (USENIX Security 14)*, pp. 191–206 (2014).
- [7] Pouryousef, S., Dar, M. D., Ahmad, S., Gill, P. and Nithyanand, R.: Extortion or Expansion? An Investigation into the Costs and Consequences of ICANN’s gTLD Experiments, *Passive and Active Measurement (Sperotto, A., Dainotti, A. and Stiller, B., eds.)*, Cham, Springer International Publishing, pp. 141–157 (2020).
- [8] Ahmad, I., Parvez, M. A. and Iqbal, A.: TypoWriter: A Tool to Prevent Typosquatting, *2019 IEEE 43rd Annual Computer Software and Applications Conference (COMPSAC)*, Vol. 1, pp. 423–432 (online), DOI: 10.1109/COMPSAC.2019.00068 (2019).
- [9] Klensin, D. J. C.: Simple Mail Transfer Protocol, RFC 5321 (2008).
- [10] Resnick, P.: Internet Message Format, RFC 5322 (2008).
- [11] ICANN: List of Top-Level Domains, ICANN (online), available from (<https://www.icann.org/resources/pages/tlds-2012-02-25-en>) (accessed 2025-1-04).
- [12] Damerau, F. J.: A technique for computer detection and correction of spelling errors, *Commun. ACM*, Vol. 7, No. 3, p. 171–176 (online), DOI: 10.1145/363958.363994 (1964).
- [13] 日本 DNS オペレーターズグループ：TOPIX 銘柄企業のドメイン名，日本 DNS オペレーターズグループ（オンライン），入手先 (<https://stats.dnsops.jp/view/jp-topix>)（参照 2025-1-04）。
- [14] 一般社団法人日本ビジネスメール協会：ビジネスメール実態調査 2024，一般社団法人日本ビジネスメール協会（オンライン），入手先 (<https://businessmail.or.jp/research/2024-result/>)（参照 2025-1-04）。
- [15] LINE ヤフー株式会社：Yahoo!クラウドソーシング，LINE ヤフー株式会社（オンライン），入手先 (<https://crowdsourcing.yahoo.co.jp/>)（参照 2025-1-05）。
- [16] 東京海洋大学：日本語話者のための英語発音講座-フォニクス-，東京海洋大学（オンライン），入手先 (<https://www2.kaiyodai.ac.jp/~takagi/pweb/fhonics.htm>)（参照 2025-1-12）。